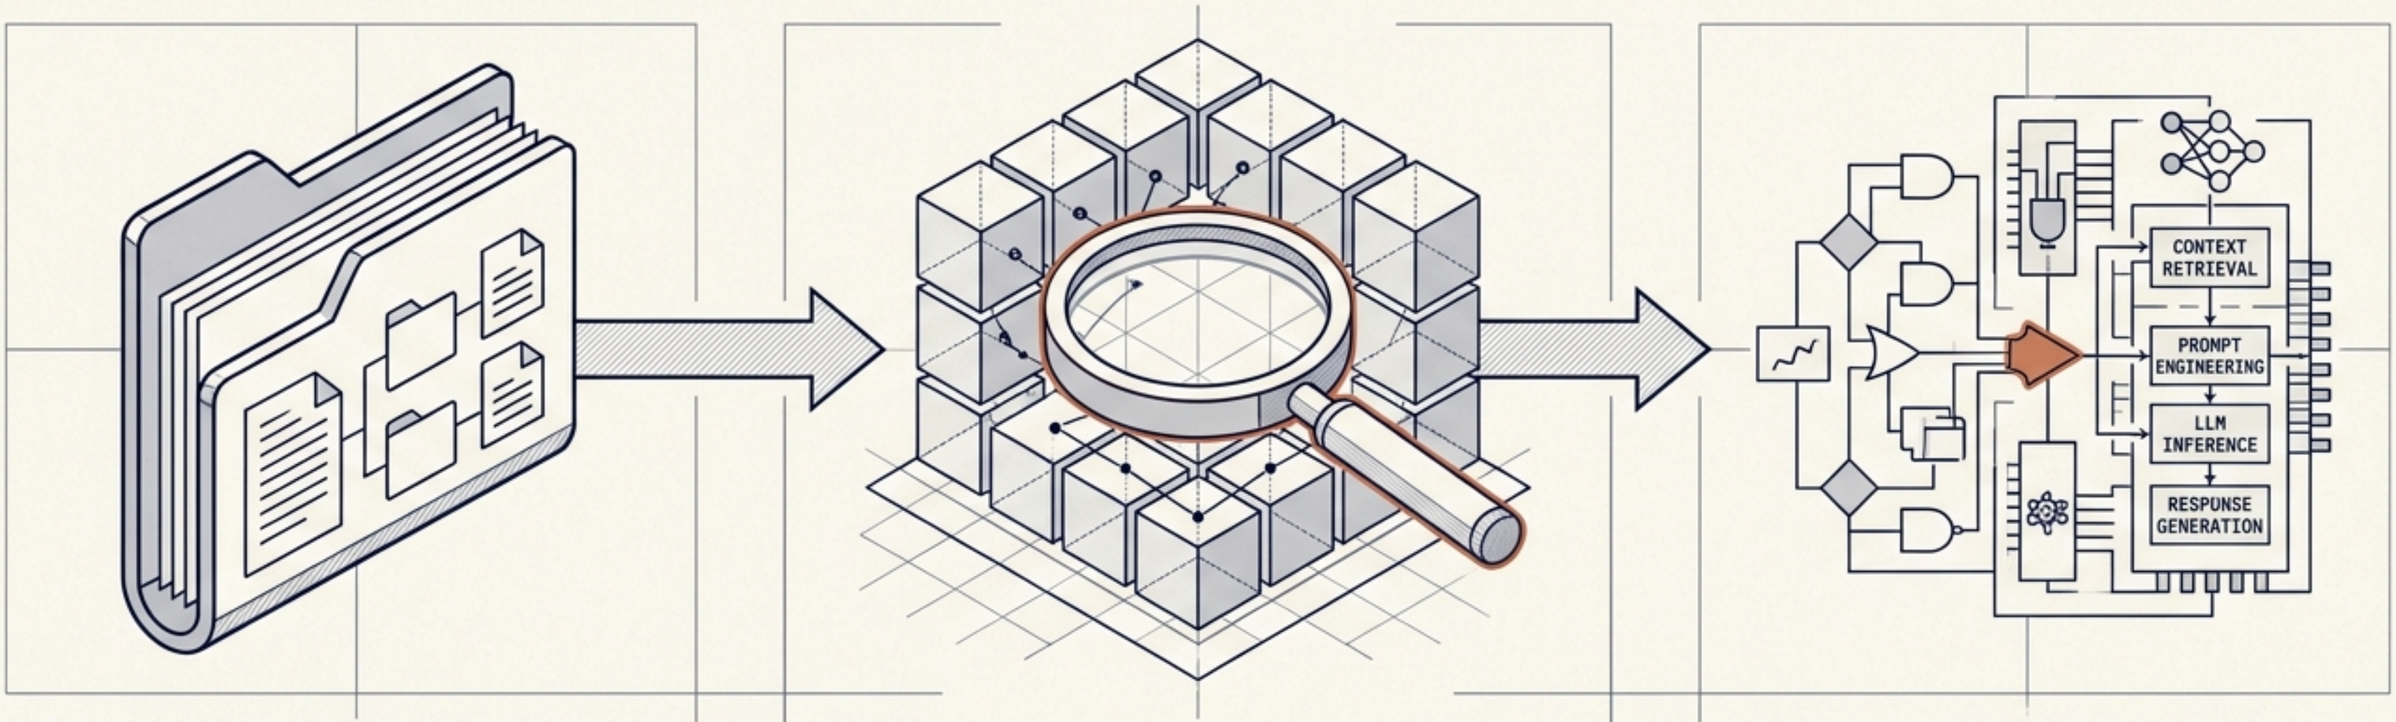
Preparatório AI-103 Certification

Arquitetura RAG na Prática: Construindo Agentes Seguros

Um guia visual para implementação corporativa usando Microsoft Azure AI Foundry e AI Search.



REPOSITÓRIO DE DOCUMENTOS
(Azure Blob/SharePoint)

VETOR SEARCH & INDEXAÇÃO
(Azure AI Search)

MODELO LLM & PROCESSAMENTO
(Azure AI Foundry)

Gemini Notebook

O Novo Paradigma da IA



Novas funções globais até 2030.



Média salarial de especialistas em IA.

O Mercado:

O mercado não precisa de mais usuários de ChatGPT. **Precisa de builders.**

O Desafio Corporativo:

Profissionais capazes de **construir agentes de inteligência artificial** que respeitem governança de dados, escalem globalmente e **integrem sistemas legados.**

A Ferramenta:

Microsoft Azure AI Foundry.



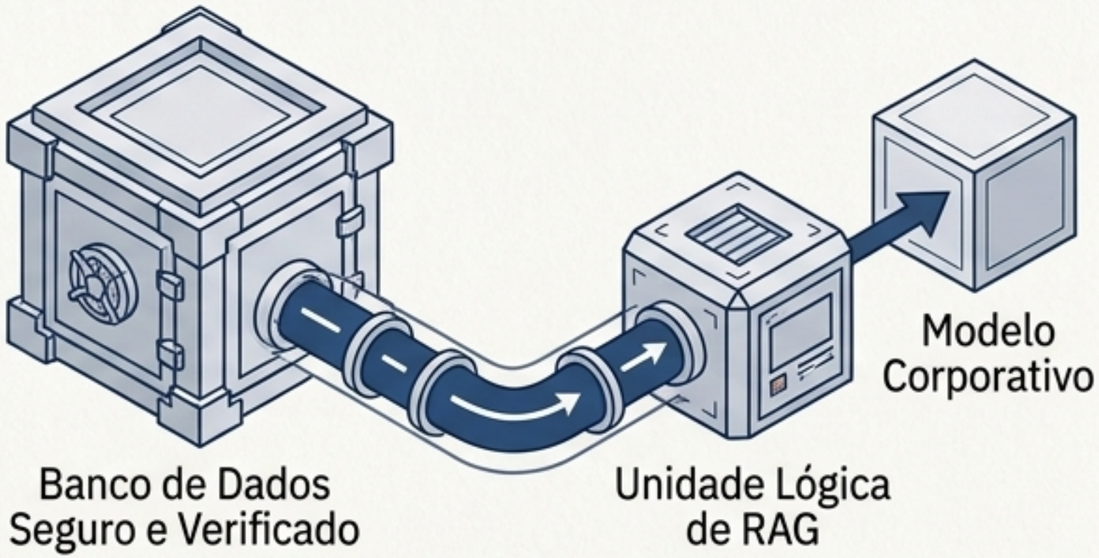
Gemini Notebook

O Preço da Alucinação nos Modelos Tradicionais

LLM Tradicional (Público)



IA Corporativa (RAG)



Alucinação:

LLMs preenchem lacunas inventando fatos com total convicção (ex: diagnósticos médicos falsos).

Desatualização:

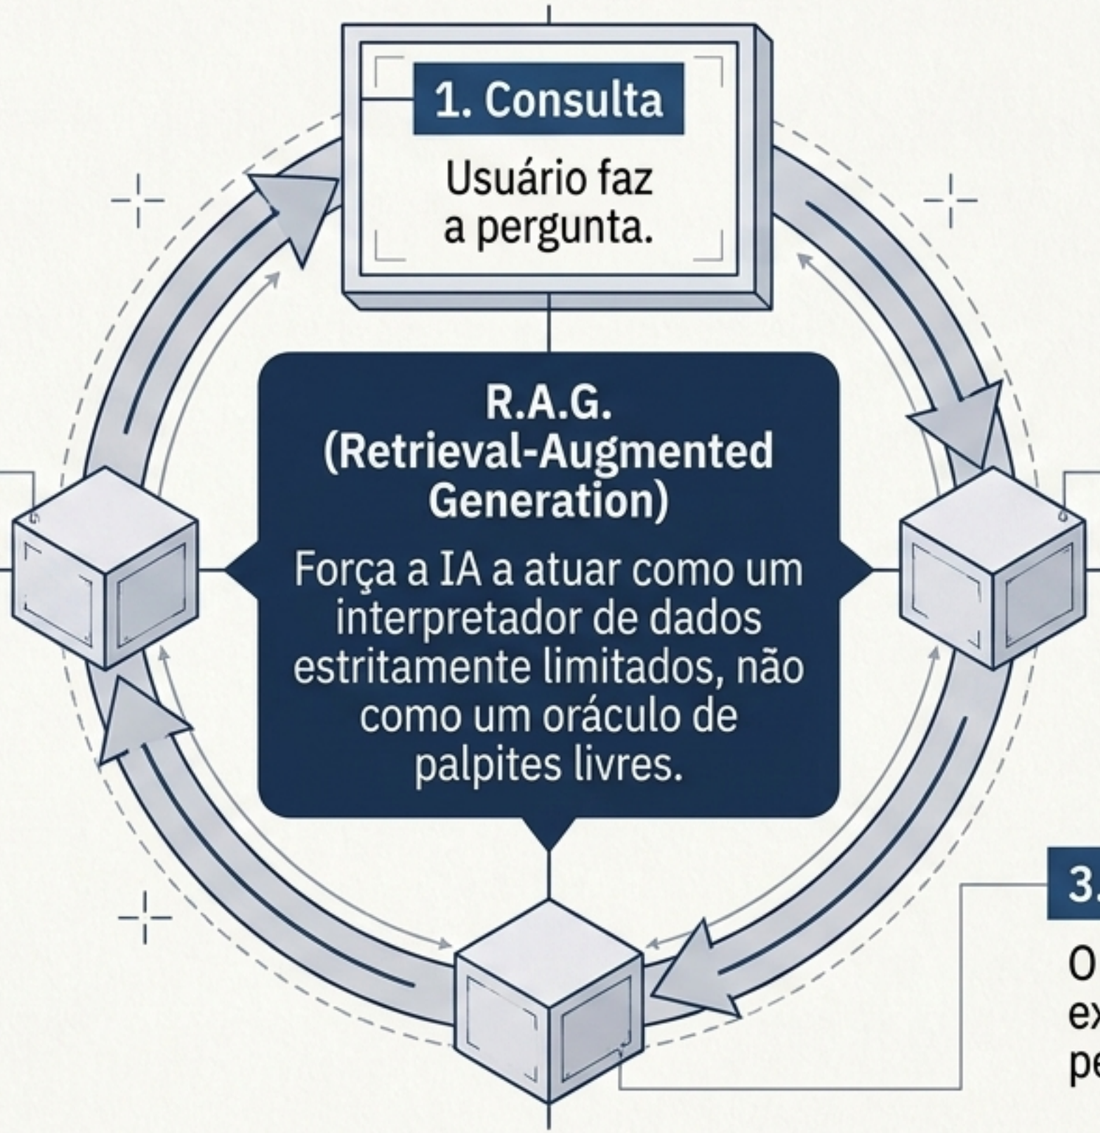
Treinamentos estáticos possuem uma data de corte. Modelos não conhecem o agora.

Vazamento e Segurança:

Expor dados proprietários a modelos públicos ou sofrer ataques de exaustão de tokens por falta de parâmetros.

Gemini Notebook

A Solução Conceptual: O que é RAG?



Gemini Notebook

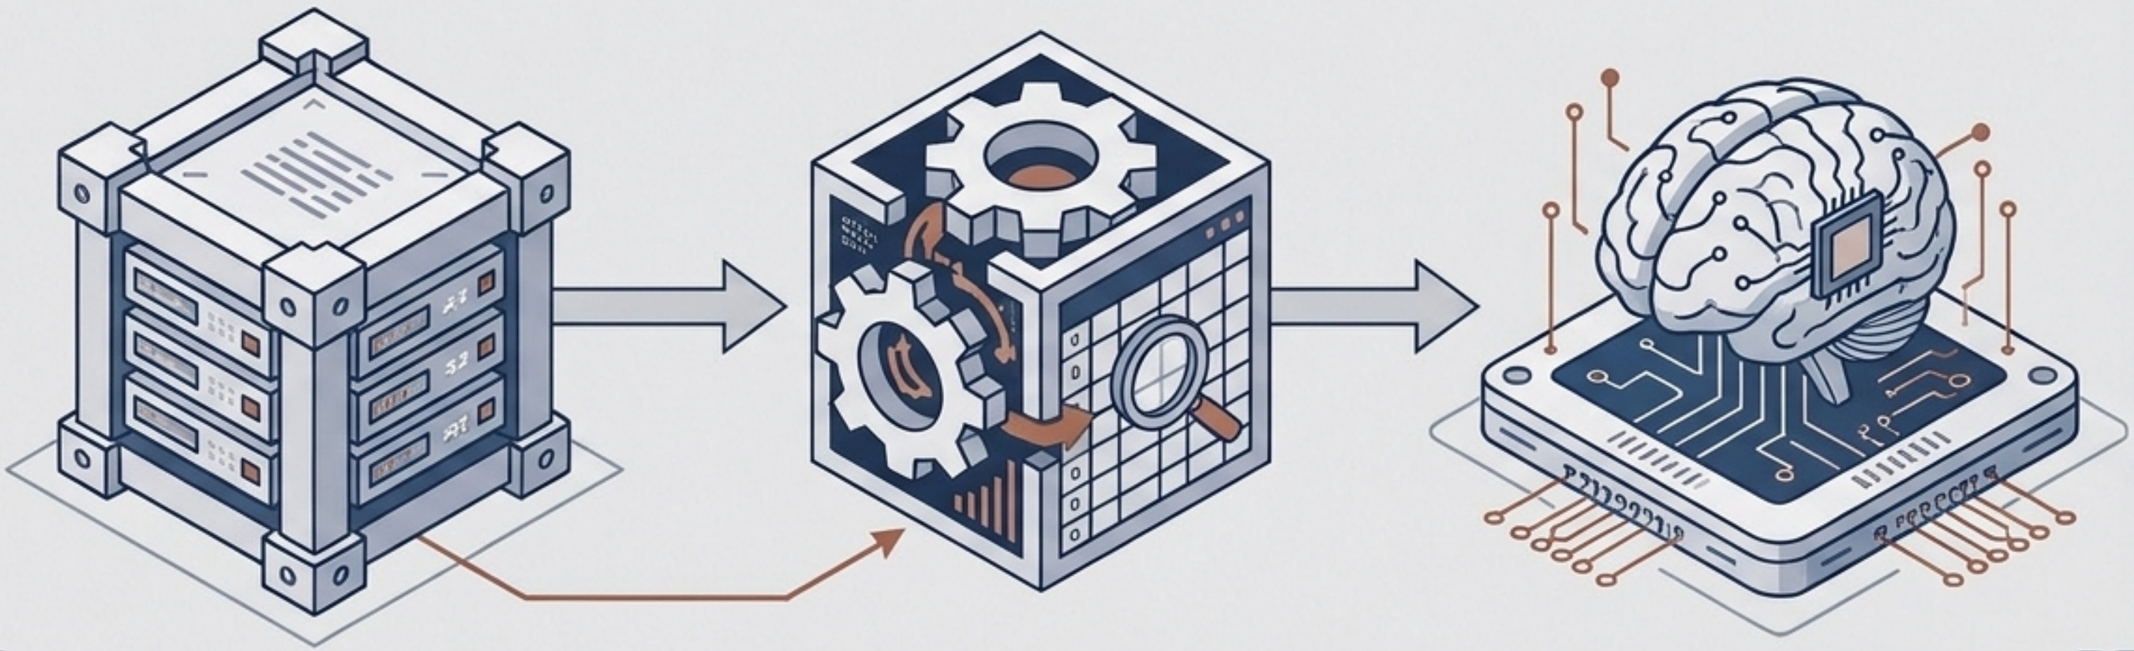
Matriz de Comparação: LLM Tradicional vs. Arquitetura RAG

Dimensão	LLM Puro (Público)	Arquitetura RAG (Azure)
Fonte da Verdade	⚠ Treinamento base da internet	✓ Dados privados e exclusivos do cliente
Conhecimento Temporal	⚠ Congelado na data de corte	✓ Atualizado em tempo real via ingestão
Auditoria e Transparência	⚠ Caixa preta, impossível rastrear a fonte	✓ Citações diretas de documentos exatos
Mitigação de Alucinação	⚠ Baixa, o modelo tenta agradar	✓ Altíssima, restrito a falhar se não achar o dado

Gemini Notebook

A Arquitetura Azure: Os Atores do Sistema

Resource Group (A Caixa Organizadora)



Azure Storage Account (Blob)

O Cofre. Onde os PDFs, manuais e dados brutos (ex: Receitas) são armazenados fisicamente.

Azure AI Search

O Motor. Indexa, vetoriza e torna o texto do cofre minerável em milissegundos.

Azure AI Foundry

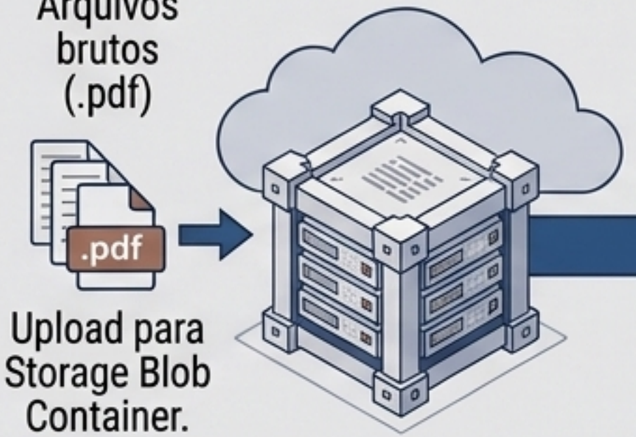
O Cérebro. Orquestra o agente LLM, gerencia os System Prompts e interage com o usuário final.

Gemini Notebook

O Fluxo de Dados (Data Pipeline)

1. Ingestão

Arquivos brutos (.pdf)



Upload para Storage Blob Container.

Azure Storage Account (Blob)

O Cofre. Onde os PDFs, manuais e dados brutos (ex: Receitas) são armazenados fisicamente.

2. Vetorização

Conexão AI Search

Quebra (Chunking) e extração de metadados



Criação de Índices.

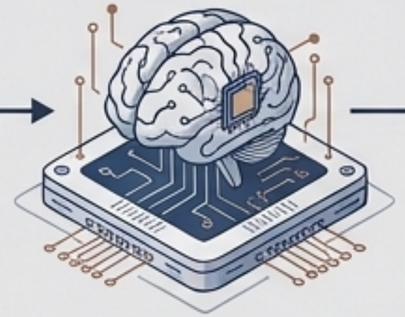
Azure AI Search

O Motor. Indexa, vetoriza e torna o texto do cofre minerável em milissegundos.

3. Orquestração

Knowledge Base do Foundry consome o Índice

Agente é implantado via API.



Azure AI Foundry

O Cérebro. Orquestra o agente LLM, gerencia os System Prompts e interage com o usuário final.

⚠ **Insight:** A conexão Import Data entre o Storage e o Search é o coração do sistema. Sem essa ponte, a IA continua cega para os seus dados corporativos.

Gemini Notebook

Passo 1: A Base - Resource Group & Storage

Camada 1: Storage Account

Resource_Group: Agrupador lógico obrigatório.

Region: East US (garante disponibilidade de serviços trial).

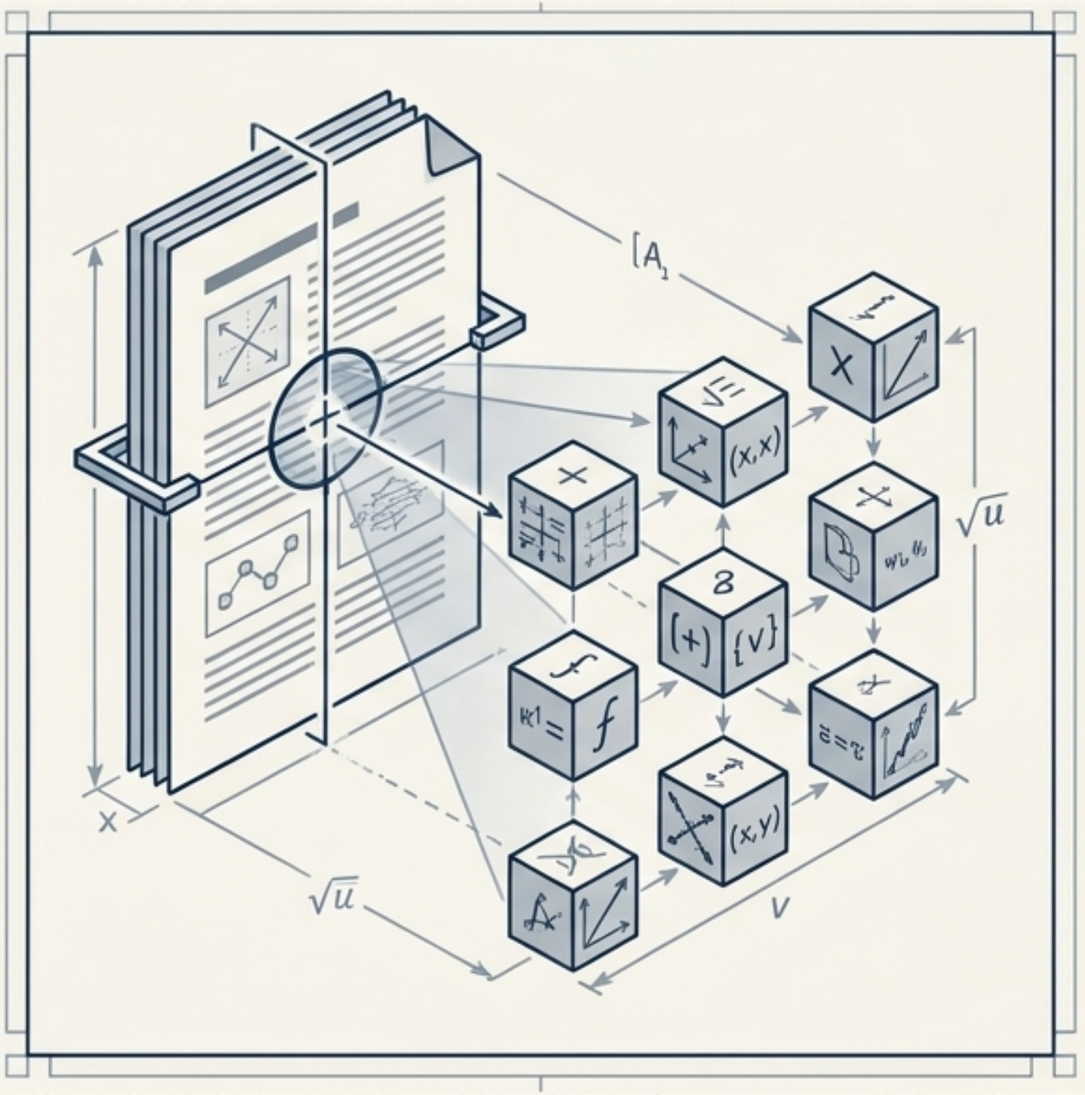
Service_Type: Armazenamento de Blob (Ideal para dados não estruturados).

Redundancy: LRS (Locally Redundant Storage) – Custo mínimo, ideal para labs.

Container_Access: Privado (Bloqueio total de acesso público).

Gemini Notebook

Passo 2: O Motor de Busca - Azure AI Search



Camada 2: Configuração AI Search

Pricing Tier:

Free (F0) para laboratório (suporta a prova de conceito sem custos astronômicos).

Indexadores:

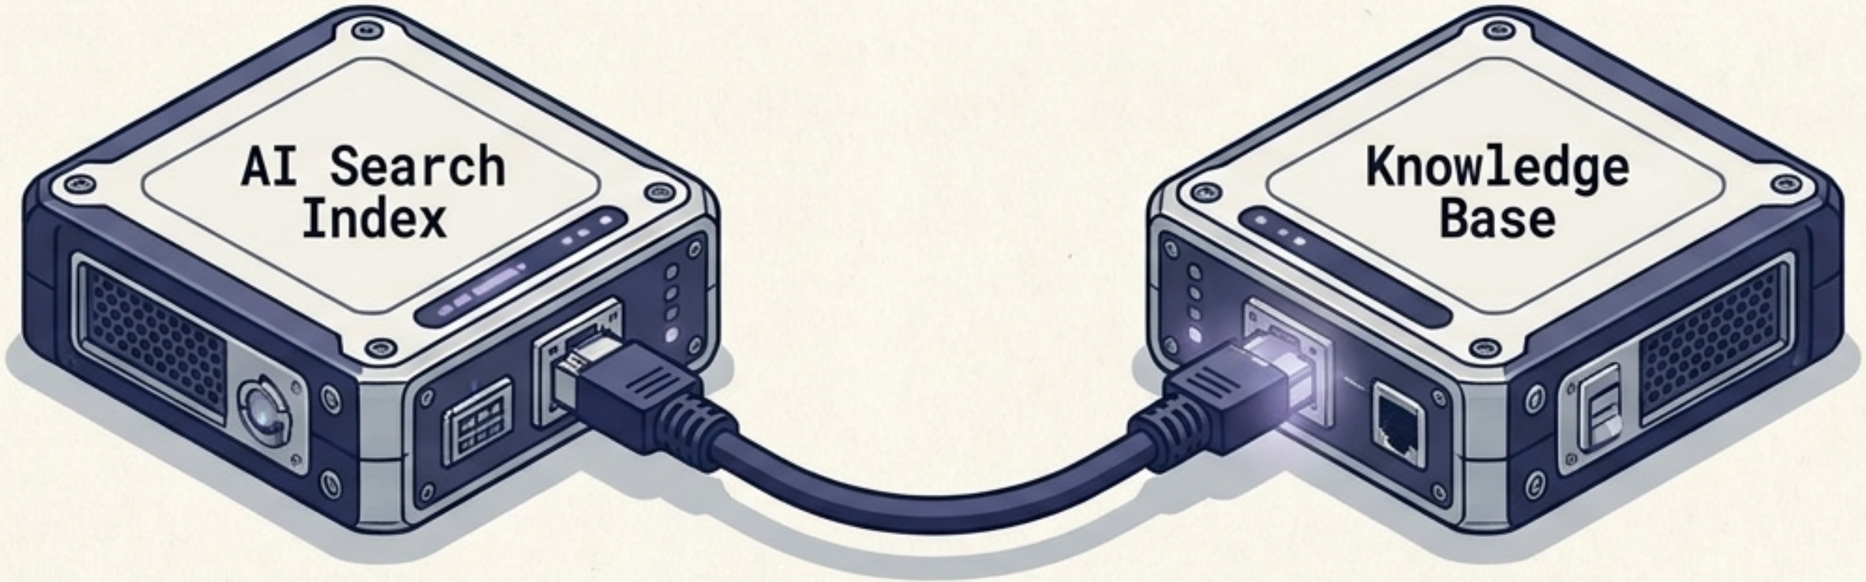
O componente vital. O indexador rastreia a Storage Account e mapeia metadados, IDs, e texto bruto.

Validação de Êxito:

⚠ Se o status do indexador não exibir Success, a base de conhecimento falhará no Foundry. A integridade do índice é o alicerce do RAG.

Gemini Notebook

Passo 3: O Agente - Azure AI Foundry



Camada 3: Orquestração no AI Foundry

Criação do Agente:

Seleção do modelo base (ex: GPT-4).

O Passo Crítico: ⚠

Adicionar o índice recém-criado no AI Search como a Base de Conhecimento do Agente.

Implantação:

Publicação do modelo que interliga a inteligência generativa com os vetores de busca corporativa.

Gemini Notebook

System Prompts: As Regras do Jogo

system_prompt_guardrails.md

Restrição 1: Responda *exclusivamente* com base nos três arquivos oficiais disponibilizados na base de conhecimento.

Restrição 2: Não utilize conhecimentos externos da internet ou suposições genéricas.

Restrição 3: Se a informação não estiver no documento, responda educadamente que não possui a resposta.

Auditoria: Ao responder, cite a fonte exata, a seção e o trecho consultado do arquivo.

A engenharia de prompt em RAG não é para melhorar o estilo; é para criar guardrails intransponíveis.

Gemini Notebook

Considerações Corporativas: Segurança e Operações



Controle de Acesso (RBAC)

Implementação estrita do Role-Based Access Control. Definição clara de quem possui permissão de Contributor versus acesso de apenas leitura.



Proteção contra Injeção

Defesa robusta contra ataques de usuários tentando burlar o bot para gastar tokens corporativos ou extrair dados sigilosos.

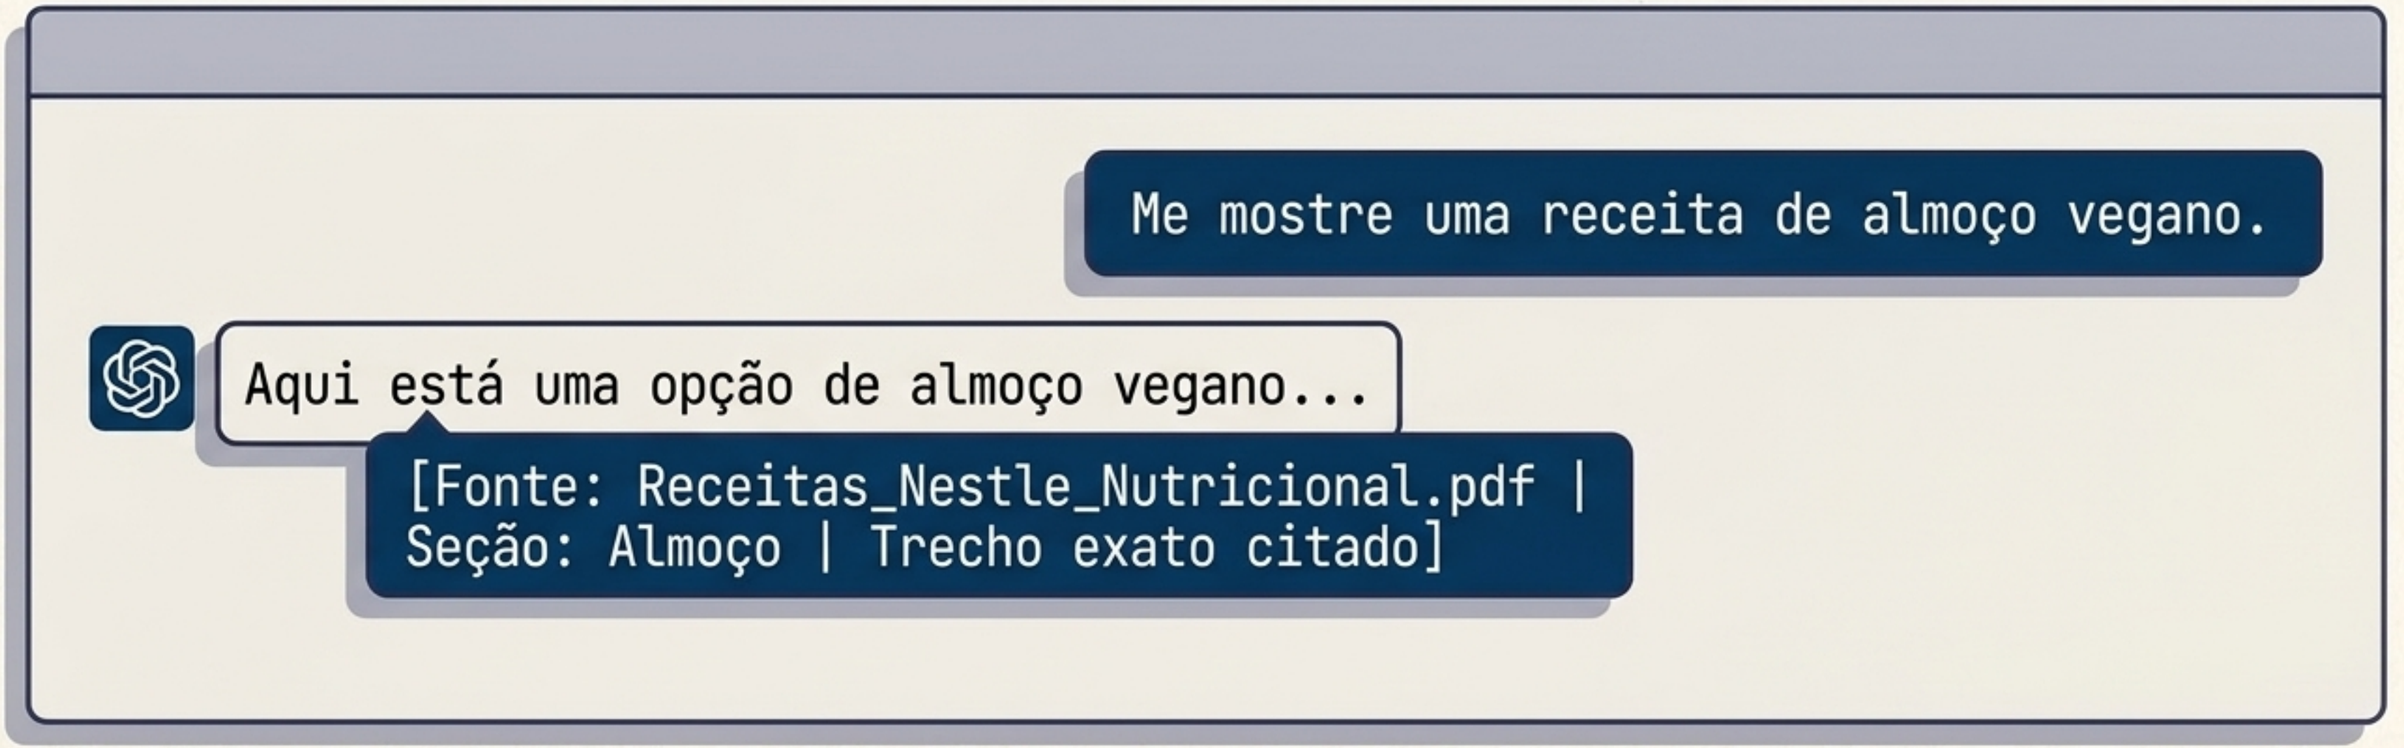


Economia e Tokens

RAG reduz custos operacionais pois o modelo não processa a internet inteira, porém o **monitoramento de requisições em massa (DDoS)** é obrigatório.

Gemini Notebook

O Ciclo de Vida da IA Generativa Privada



- O domínio absoluto desta arquitetura (Storage + Search + Foundry) é o núcleo para aprovação na certificação AI-103 e para o sucesso em implantações Enterprise.
- O dado é seu. O motor é o Azure. O resultado é seguro.

Gemini Notebook